

Introduction à l'Intelligence Artificielle

Introduction à l'Intelligence Artificielle

Des systèmes experts aux modèles génératifs



ParisTech



Conférence — mai 2026

Antoine Sabot-Durand

- Directeur technique chez SCIAM
- En charge de la stratégie IA et de l'innovation
- Architecte IT
- Java Champion, ancien CDI spec lead, ancien MicroProfile Health et Fault Tolerance spec lead
- Suivez-moi sur Bluesky : [@antoine.sabot-durand.net](https://bsky.app/profile/antoine.sabot-durand.net)



Sommaire

1. Histoire de l'IA — des origines aux LLMs
2. Les Transformers — comment ça marche vraiment
3. IA en chimie — AlphaFold et au-delà
4. Le futur — raisonnement, AGI

« L'intelligence artificielle est peut-être l'un des effets de levier les plus importants de l'histoire de l'humanité. »

Prix Nobel de Physique 2024
— Geoffrey Hinton

Partie 1

Histoire de l'Intelligence Artificielle

Des systèmes experts aux réseaux de neurones profonds

1950 — La question de Turing


”Can machines think ?”

Alan Turing pose la question en 1950 dans *Computing Machinery and Intelligence*.

Il propose le Test de Turing : si un humain ne peut pas distinguer la machine de l'humain dans une conversation, la machine est "intelligente".

Ce test est-il la bonne mesure ?

→ Non, mais il a structuré 70 ans de recherche.



*Alan Turing (1912-1954) — père de l'informatique théorique
(Wikimedia Commons / photographie de 1928)*

1956 — La naissance officielle du terme "IA"

Dartmouth Conference (1956)

John McCarthy, Marvin Minsky, Claude Shannon, Nathaniel Rochester

→ Naissance officielle du terme "Artificial Intelligence"

Hypothèse centrale

"Every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it."

Optimisme débridé

"Dans 20 ans, les machines feront tout ce qu'un humain peut faire."

(Spoiler : c'était trop optimiste... mais l'intuition était juste)

1960-1970 — L'IA symbolique : la règle comme intelligence

Le paradigme Good Old-Fashioned AI (GOFAI)


L'intelligence = manipulation de symboles selon des règles logiques

```
(DEFUN est-spam (email)
  (AND (contient-mot "urgent" email)
        (expediteur-inconnu email)))
```

LISP (1958, McCarthy) devient le langage de l'IA.

Résultats impressionnants :

- ELIZA (1966) — chatbot thérapeutique
- SHRDLU (1970) — compréhension de phrases en monde de blocs



```
ELIZA - MIT, 1966 - Terminal MAD-SLIP

HOW DO YOU DO. PLEASE TELL ME YOUR PROBLEM.
I feel very sad because I failed my chemistry exam.
WHY DO YOU FEEL VERY SAD ?
I failed my chemistry exam and my professor is angry.
DOES IT PLEASE YOU TO BELIEVE YOUR PROFESSOR IS ANGRY ?
Maybe. I think I don't understand organic chemistry.
DO YOU REALLY THINK YOU DON'T UNDERSTAND ORGANIC
CHEMISTRY ?
Yes, the reaction mechanisms are too complex.
EARLIER YOU SAID YOUR PROFESSOR IS ANGRY.
HOW DOES THAT MAKE YOU FEEL ABOUT MECHANISMS ?
Confused...
█
```

ELIZA — premier chatbot, simulant un psychothérapeute rogérien

1980 — Les systèmes experts : l'IA industrielle

Le modèle SI-ALORS

Un système expert encode la connaissance d'un expert humain sous forme de règles :

```
SI température > 38.5°C  
ALORS patient a de la fièvre  
  
SI patient a de la fièvre  
  ET toux = PRÉSENTE  
ALORS risque grippal = ÉLEVÉ
```

DENDRAL (1965) — Stanford Identification de structures chimiques par spectrométrie de masse

MYCIN (1972) — Diagnostic médical → Performances supérieures aux médecins humains dans son domaine

La limite fondamentale

La connaissance du monde ne peut pas être encodée à la main

- Des milliers de règles à maintenir
- Connaissance fragmentée, pas de généralisation
- Incapacité à apprendre de nouveaux exemples
- "Brittleness" : hors domaine = échec total

L'hiver de l'IA frappe en 1987 : financement s'effondre, promesses non tenues

1997 — Deep Blue : les machines battent les champions

Un tournant symbolique

11 mai 1997 : Deep Blue (IBM) bat Garry Kasparov au jeu d'échecs (3,5 – 2,5).

Ce que Deep Blue n'est PAS :

Deep Blue ne "pense" pas — il évalue 200 millions de positions/seconde avec des heuristiques codées à la main.

Mais le signal est clair : les machines peuvent surpasser les humains dans des domaines formalisables.

1996-2016 — Succès de l'IA symbolique hybride :

- Reconnaissance de chèques bancaires (LeCun, 1998)
- Spam filtering (Naive Bayes)
- Moteurs de recommandation



IBM Deep Blue — premier programme à battre un champion du monde d'échecs en titre
(© Wikimedia Commons / IBM)

1986-1995 — Le Machine Learning : laisser les données parler

Du "programmer" à "apprendre"


Paradigme shift fondamental :

IA classique	Machine Learning
Humain écrit des règles	Machine apprend des règles depuis les données
Représentation manuelle	Représentation automatique
Expertise explicite	Patterns cachés dans les données

Algorithmes clés :

- Perceptron (Rosenblatt, 1958) — premier neurone artificiel
- Backpropagation (Rumelhart, Hinton 1986) — réseaux de neurones multi-couches
- SVM — Support Vector Machines (Vapnik 1995)
- Arbres de décision, forêts aléatoires

Le perceptron : premier neurone artificiel



*Le perceptron de Rosenblatt (1958) : somme pondérée des entrées + seuil d'activation.
Limite : seulement les problèmes linéairement séparables. La backpropagation (1986) permettra d'empiler les couches.*

2006-2012 — La renaissance : le Deep Learning

Geoffrey Hinton & co. relancent les réseaux profonds

Problème historique : les réseaux profonds ne s'entraînaient pas bien (vanishing gradient)


Solutions :

- Pre-training couche par couche (Hinton 2006)
- Nouvelles fonctions d'activation (ReLU)
- Dropout (régularisation)
- GPU comme accélérateur d'entraînement

ImageNet 2012 → révolution AlexNet

Taux d'erreur ImageNet :
Meilleure méthode classique : 26.2%
AlexNet (deep learning) : 15.3%

→ Gain de 10 points d'un coup. L'ère du deep learning commence.



Architecture d'un réseau de neurones : couches d'entrée, cachées, sortie.
La profondeur (10-1000+ couches) permet d'apprendre des représentations hiérarchiques : pixels → bords → formes → objets
(© Wikimedia Commons)

2017 — "Attention is All You Need"

We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely.

Google Brain 2017
— Vaswani et al.

Ce papier change tout :

- Plus de RNN (lents, difficile à paralléliser)
- L'attention permet de voir tout le contexte en une seule opération
- Scalable sur GPU/TPU


6 ans plus tard : GPT-4, Gemini, Claude, Mistral... sont tous des Transformers

Voir la partie suivante pour comprendre le mécanisme

2020-2024 — L'explosion des LLMs

La loi de scaling : doubler les données $\times$ la taille du modèle $\rightarrow$ performance prévisible
(Kaplan et al., OpenAI 2020)

2020-2024 — L'explosion des LLMs




2018

BERT
(Google)
110M
params

La loi de scaling : doubler les données $\times$ la taille du modèle $\rightarrow$ performance prévisible
(Kaplan et al., OpenAI 2020)

2020-2024 — L'explosion des LLMs



2018

BERT
(Google)
110M
params




2020

GPT-3
(OpenAI)
175B params

La loi de scaling : doubler les données $\times$ la taille du modèle $\rightarrow$ performance prévisible
(Kaplan et al., OpenAI 2020)

2020-2024 — L'explosion des LLMs



2018

BERT
(Google)
110M
params



2020

GPT-3
(OpenAI)
175B params




2022

ChatGPT
1M users en
5 jours

La loi de scaling : doubler les données $\times$ la taille du modèle $\rightarrow$ performance prévisible
(Kaplan et al., OpenAI 2020)

2020-2024 — L'explosion des LLMs



2018

BERT
(Google)
110M
params



2020

GPT-3
(OpenAI)
175B params



2022

ChatGPT
1M users en
5 jours



2023

GPT-4,
Gemini,
Llama
Multimodal

La loi de scaling : doubler les données $\times$ la taille du modèle $\rightarrow$ performance prévisible
(Kaplan et al., OpenAI 2020)

2020-2024 — L'explosion des LLMs



La loi de scaling : doubler les données × la taille du modèle → performance prévisible
(Kaplan et al., OpenAI 2020)

Récapitulatif : IA, Machine Learning, Deep Learning, IA Générative


Les relations entre les concepts

Pensez à des cercles concentriques :

IA $\supset$ Machine Learning $\supset$ Deep Learning $\supset$ IA Générative

- IA = domaine très large (70+ ans d'histoire)
- Machine Learning = sous-ensemble qui apprend des données
- Deep Learning = sous-ensemble avec réseaux profonds (10+ couches)
- IA Générative = sous-ensemble qui crée du contenu nouveau

Vision synthétique de l'évolution



Chaque génération a amené une augmentation de puissance de calcul et de données

Tableau comparatif : les trois paradigmes

Aspect	Machine Learning	Deep Learning	IA Générative
Période clé	1986-2012	2012-2020	2020+
Technologie	Divers (SVM, arbres, RF)	Réseaux neuronaux profonds	Transformers & Diffusion
Profondeur	Peu/moyen de couches	10 à 1000+ couches	96-200+ couches
Données	Milliers à millions	Millions à milliards	Centaines de milliards
Calcul	CPU suffisant	GPU/TPU	GPU/TPU clusters
Ce qu'il fait	Classification, prédiction	Reconnaissance avancée	Génération de contenu
Exemple	Détecteur spam	ImageNet (2012)	ChatGPT, DALL-E

La révolution générative : changement de paradigme

Machine Learning = prédire une catégorie / un nombre

Deep Learning = extraire et reconnaître des patterns complexes

IA Générative = prédire la suite d'une séquence (token, pixel, frame...)

→ Trois mots-clés, trois objectifs différents, une même mathématique sous-jacente (l'optimisation)

Pendant 30 ans, l'IA a appris à **reconnaître** et **classifier** le monde.

Depuis 2020, elle apprend à **générer** et **créer**.

Cette transition change tout — et c'est juste le début.

Partie 2

Comment fonctionnent les Transformers
Plongée dans le mécanisme qui révolutionne l'IA

Intuition : prédire le prochain mot

Exercice mental :

Pour faire une omelette, il faut d'abord casser des _

Vous avez deviné : œufs — et probablement avec un haut degré de confiance.

C'est exactement ce que fait un LLM — mais sur des milliards d'exemples de texte.

Un modèle entraîné uniquement à prédire le prochain token apprend implicitement la syntaxe, la sémantique, les faits du monde... et même le raisonnement.

Pourquoi ? Parce que pour prédire correctement, il faut comprendre.

Les embeddings : les mots dans l'espace vectoriel

En pratique :

- Chaque token devient un vecteur dense (appris)
- La proximité géométrique approxime la proximité de sens
- Les relations sémantiques émergent des données

Embeddings : représentation vectorielle

Chaque mot est projeté dans un espace de grande dimension ($N = 768, 1024, 4096\dots$).

chat	$\mapsto [0.23, -0.87, 0.41, \dots]$	
chien	$\mapsto [0.25, -0.84, 0.39, \dots]$	(proche)
voiture	$\mapsto [-0.71, 0.12, -0.55, \dots]$	(loin)


Ces vecteurs sont appris automatiquement pendant l'entraînement.

Embeddings : relations et visualisation

Propriété remarquable : certaines relations s'expriment comme des déplacements vectoriels.

$\text{roi} - \text{homme} + \text{femme} \approx \text{reine}$

$\text{Paris} - \text{France} + \text{Italie} \approx \text{Rome}$



Projection 2D d'embeddings (t-SNE) : les mots sémantiquement proches sont proches dans l'espace vectoriel

L'attention : "qui regarde qui" ?

L'attention répond à une question simple :

- Pour chaque token, quels autres tokens sont pertinents ici ?
- Avant les Transformers, les RNN traitaient le texte séquentiellement. Avec la self-attention, tous les tokens sont traités en parallèle.

"Le chat s'est endormi dans le fauteuil parce qu'il était fatigué"

- Pour résoudre "il" → forte attention sur "chat"
- Pour comprendre "fatigué" → attention sur "chat" et "endormi"

L'attention multi-têtes : regarder sous différents angles

Une seule tête = une seule perspective. Le multi-head combine plusieurs perspectives en parallèle.

Multi-Head : principe

Au lieu d'une seule attention, le Transformer utilise H têtes en parallèle.

Chaque tête apprend une projection différente de la séquence.

Les sorties de toutes les têtes sont concaténées puis reprojétées.


Multi-Head : ce que les têtes capturent

Exemples typiques de spécialisations :

- syntaxe (sujet-verbe)
- co-références (il/le chat)
- dépendances longues distance
- relations temporelles (avant/après)

Multi-Head : ordre de grandeur

GPT-4 : 96 têtes/couche $\times$ 96 couches $\approx$ 9 216 regards simultanés



Multi-Head Attention : projections parallèles puis concaténation

Génération de texte : chercher le meilleur token

Trois idées pour lire cette partie :

- Le décodage choisit une séquence, pas seulement un mot
- La température et le sampling contrôlent le style de sortie
- Le pré-entraînement + alignment expliquent le comportement final

Décodage : greedy vs beam search

Greedy search : choisir à chaque étape le token le plus probable.

Limite : un choix local optimal peut produire une phrase globale moins bonne.

Beam search : explorer N séquences en parallèle, puis garder la meilleure séquence globale.

Sampling : température, top-k, top-p

Température (créativité) :

- $T \rightarrow 0$: déterministe
- $T = 1$: distribution naturelle
- $T > 1$: plus créatif, plus risqué

Top-k sampling : tirage aléatoire parmi les k tokens les plus probables.

Top-p (nucleus) sampling : tirage dans le plus petit ensemble couvrant p% de probabilité cumulée.


Entraînement : 3 phases + scaling laws

Phase 1 — Pre-training : prédire le prochain token sur un très grand corpus.

Phase 2 — SFT : apprendre à suivre des consignes.

Phase 3 — RLHF : aligner les réponses sur les préférences humaines.

$$\text{Performance} \approx f(N_{\text{params}} \times N_{\text{tokens}} \times \text{compute})$$



La performance améliore de façon prévisible (loi puissance) avec le compute

Limites et hallucinations

Les LLMs peuvent être impressionnants et se tromper avec assurance.

Pourquoi les hallucinations existent ?

Un LLM n'est pas un moteur de recherche : il prédit la suite la plus probable.

Conséquence : il peut produire des faits inventés, sources fictives ou chiffres erronés.

Réduction du risque (sans garantie totale)

- grounding par sources vérifiées (RAG)
- alignment via feedback humain (RLHF)
- contrôles applicatifs (validation, citations, garde-fous)

Règle opérationnelle : vérifier systématiquement faits, dates, chiffres et références.

Capacités émergentes

À grande échelle apparaissent aussi :

- raisonnement en chaîne
- analogies inter-domaines
- génération de code
- traduction sans supervision explicite

Ces capacités n'ont pas été codées explicitement : elles émergent de l'entraînement prédictif.

Au-delà du texte : les Transformers partout

Le Transformer est devenu une architecture générale de modélisation de séquences.

→ Un principe commun pour des domaines très différents.

Image, mélodie, ADN, code : tout peut devenir une séquence de tokens.

Exemples concrets hors texte

Domaine	Modèle	Input	Output
Images	DALL-E, Midjourney	Texte	Image
Code	GitHub Copilot	Code incomplet	Complétion
Musique	MusicLM, Suno	Texte	Audio
Protéines	AlphaFold	Séquence AA	Structure 3D
Molécules	ChemBERTa	SMILES	Propriétés
Science	Galactica	Question	Réponse scientifique

RAG : donner une "mémoire externe" au LLM

RAG = Retrieval-Augmented Generation : on fait d'abord une recherche dans une base de connaissances, puis on demande au LLM de répondre avec ce contexte.

Version vulgarisée :

- Un LLM seul répond de mémoire (parfois bien, parfois faux)
- Un système RAG lui "ouvre le classeur" avant qu'il réponde
- La réponse est plus fiable et plus traçable

RAG : fonctionnement en 4 étapes

1) Préparer la base

On découpe les documents en petits morceaux (chunks), puis on les convertit en vecteurs (embeddings).

2) Chercher les passages utiles

La question utilisateur est vectorisée, puis on récupère les k passages les plus proches dans la base vectorielle.


3) Construire le prompt

On injecte question + passages retrouvés dans le prompt envoyé au LLM.

4) Générer la réponse

Le LLM répond en s'appuyant sur le contexte fourni (et idéalement avec citations de sources).

Architecture type d'un RAG



Pipeline simplifié : indexation des documents, retrieval, prompt augmenté, génération de réponse.

RAG : ce que ça améliore... et ses limites

Le RAG réduit les hallucinations, mais ne les supprime pas totalement.

Ce que ça améliore :

- Réponses plus factuelles sur un domaine précis
- Possibilité de citer les sources utilisées
- Mise à jour des connaissances sans réentraîner le modèle

Limites à garder en tête :

- Mauvais retrieval = mauvaise réponse
- Contexte trop long ou bruité = confusion
- Toujours besoin de validation humaine pour les cas critiques

Règle pratique : qualité d'un RAG = qualité des documents + qualité de l'indexation + qualité du retrieval.

Partie 3

L'IA Révolutionne la Chimie

AlphaFold, drug discovery, synthèse et au-delà

AlphaFold : résoudre un problème vieux de 50 ans


Le problème : les protéines se replient selon des règles physiques, mais prédire la bonne forme en 3D depuis la simple séquence d'acides aminés était IMPOSSIBLE — même les meilleurs ordinateurs échouaient depuis 50 ans.

Avant AlphaFold :

- Structurale par cristallographie aux rayons X = 2-5 ans de travail
- Coûteux, long, sans garantie
- Seulement ~180 000 structures connues pour les millions de protéines existantes
- Les chercheurs étaient bloqués

La révolution (2021) :

AlphaFold2 prédit la structure 3D en quelques secondes avec une précision comparable à l'expérience !



Structure 3D d'une protéine (myoglobine). Les couleurs indiquent la confiance de la prédiction.

Résultat : 214 millions de structures prédites et librement accessibles. Chaque chercheur du monde peut maintenant voir

Impact réel : de la théorie aux applications

Où le changement se voit :

- Malaria & maladies infectieuses

Identifié rapidement les protéines critiques du parasite → nouvelles cibles thérapeutiques en mois, pas en années.

- Enzymes industrielles

Optimisation automatisée des enzymes pour la chimie verte, les biofuels, les détergents.

- Drug discovery

40-50% de réduction du temps pour comprendre si une molécule candidate peut se fixer au bon endroit.

- AlphaFold3 (2024)


Étendu aux molécules petites, ADN, ARN, ions – l'IA voit maintenant les mécanismes complets de la vie moléculaire.

Drug Discovery : accélérer la quête du médicament

Le problème : développer un nouveau médicament prend 10-15 ans et 2+ milliards de dollars. L'IA peut réduire ce délai d'années entières.

Où l'IA économise du temps :

1. Sélection des cibles — Analyser en secondes des données génomiques pour identifier LE bon endroit à attaquer
2. Criblage virtuel — Tester informatiquement si 1 million de molécules se lient bien, vs les tester en labo
3. Génération guidée — L'IA propose directement des molécules avec les bonnes propriétés



Insilico Medicine : cible identifiée (2019) → molécule générée (21 jours) → essais cliniques approuvés (2023)

Vs classique : 4-5 ans pour atteindre ce stade

Résultat concret : Des médicaments pour maladies rares et maladies infectieuses arrivent 4× plus vite au stade de test en humain.

Génération de molécules : l'IA crée des molécules inexistantes


Le problème : concevoir une molécule avec des propriétés spécifiques (solubles, efficaces, pas toxiques) est un puzzle combinatoire gigantesque. L'IA apprend à naviguer cet espace.

Comment représenter une molécule à l'ordinateur ?

- SMILES : notation textuelle (comme "CC(=O)Oc1ccccc1C(=O)O" = Aspirine)
- Graphes : atomes = nœuds, liaisons = connexions
- Structures 3D : vraies coordonnées atomiques

Ce que l'IA apprend :

L'IA entraînée sur des millions de molécules réelles apprend des patterns : "si tu veux une molécule soluble, ajoute cet groupe chimique"



L'IA navigue dans l'espace des molécules possibles pour trouver celle avec les bonnes propriétés

Résultat : Molécules entièrement nouvelles générées en secondes, avec des propriétés prédéfinies. Exscientia a découvert un médicament contre le TOC en 12 mois (vs 4.5 ans en moyenne).

IA pour l'analyse : savoir ce qu'on a fabriqué

Le problème : identifier une molécule inconnue ou détecter des contaminants au contrôle qualité. Tâche manuelle lente et coûteuse.

Spectroscopie + IA

- RMN (résonance magnétique nucléaire) — L'IA prédit les spectres → Identification en secondes
- IR/Raman — L'IA détecte les falsifications alimentaires ou les impuretés
- Spectrométrie de masse — Identification de molécules inconnues par IA (SIRIUS)

Résultats concrets :

- ✓ P&G : détecte les défauts cosmétiques 200× plus précis que l'humain (0.01% vs 2% d'erreur)
- ✓ Raman portable : détecte le méthanol dans l'alcool frelaté en terrain
- ✓ Performances en 2023 = niveau expert humain en quelques minutes

Synthèse organique : l'IA planifie le chemin chimique

Le problème : synthétiser une molécule complexe = trouver une séquence de réactions parmi des billions de chemins possibles. Même les chimistes experts explorent laborieusement.

Rétrosynthèse assistée par IA

Au lieu de tester manuelle réactions :

✓ AiZynthFinder (AstraZeneca) : trouve une route synthétique valide en secondes

✓ IBM RXN : Transformer entraîné sur 2.5 millions de réactions chimiques

→ Prédit les produits de réaction avec >80% d'exactitude

Résultat : plan de synthèse en minutes, pas en semaines

Chimie computationnelle ultra-rapide

L'IA apprend à prédire les propriétés sans calcul quantique (DFT) coûteux.

MACE-MP-0 (2023) : modèle universel prédit les propriétés d'énormes systèmes → transfert à des molécules jamais vues
→ 1000× plus rapide que les calculs classiques

Découverte de matériaux : la révolution automatisée

Le problème : trouver un nouveau matériau avec les propriétés désirées (meilleure batterie, photocatalyseur, supraconducteur) = explorer un univers de combinaisons infinies.

Le changement de paradigme

Avant IA : concevoir → synthétiser → tester → attendre résultats (mois)

Avec IA : prédire stabilité → prédire propriétés → robots synthétisent et testent automatiquement

GNoME (Google DeepMind, 2023) :

- Prédit 2.2 millions de nouveaux cristaux stables
- 380 000 validés expérimentalement par robots automatisés
- Accélération : 50 ans de travail en quelques mois

Applications réelles en 2024+

- ✓ Batteries Li-ion — Électrolytes plus stables et plus conducteurs
- ✓ Énergie verte — Photocatalyseurs pour H₂, capture CO₂
- ✓ Informatique — Matériaux plus efficaces énergétiquement
→ Chaque avancée = années gagnées avant commercialisation

Partie 4

Le Futur de l'IA

Raisonnement, agents, et la question de l'AGI

L'IA dans votre quotidien professionnel : une compétence à part entière

L'IA ne va pas remplacer les ingénieurs.
Mais les ingénieurs qui savent utiliser l'IA vont remplacer ceux qui ne savent pas.

Ce qui change dans votre métier

Ce que l'IA fait déjà très bien

- Générer un premier jet de code, de rapport, de résumé
- Rechercher et synthétiser de la littérature scientifique
- Proposer des pistes expérimentales depuis un problème
- Analyser des données et produire des visualisations
- Rédiger des e-mails, comptes-rendus, présentations

Gain de temps réel : 20-40% sur les tâches de production de contenu selon les études (McKinsey, 2024)

Ce que l'IA ne remplace pas (encore)

- Le jugement scientifique : interpréter un résultat inattendu
- La créativité de rupture : poser une nouvelle question
- La responsabilité : signer un résultat, assumer une décision
- Le travail expérimental : manipuler, observer, sentir, tâtonner
- La relation humaine : convaincre, collaborer, enseigner

Un ingénieur qui délègue son jugement à l'IA sans vérifier devient moins compétent avec le temps.

Maîtriser l'IA : trois postures à adopter

1) Le scepticisme actif

L'IA affirme avec assurance — même quand elle invente.

- Toujours vérifier les faits, les sources, les chiffres
- Ne jamais signer un document généré par IA sans relecture critique
- Traiter l'IA comme un stagiaire brillant mais non fiable

2) Le prompt engineering

La qualité de la sortie dépend de la qualité de la question.

❌ "Explique-moi AlphaFold"

✅ "Tu es un biochimiste. Explique en 5 bullet points comment AlphaFold2 prédit la structure d'une protéine, pour un ingénieur chimiste sans background bio."

- Contexte + rôle + format + contraintes = meilleur résultat

3) L'orchestration

Ne pas utiliser l'IA comme un oracle isolé, mais comme un outil dans un workflow :

- Décomposer les tâches complexes en étapes
- Valider les sorties intermédiaires
- Combiner IA + expertise humaine + sources fiables

Les meilleurs utilisateurs d'IA sont ceux qui savent quand ne pas l'utiliser.

Enjeux sociétaux : les questions que vous aurez à affronter

Dans votre entreprise

Propriété intellectuelle : qui détient le brevet d'une molécule co-conçue avec une IA ?

Traçabilité : comment auditer une décision prise par un modèle opaque ?

Inégalités d'accès : GPT-4 coûte cher — les PME et pays en développement sont-ils exclus ?

Dépendance technologique : OpenAI, Google, Anthropic... toute la chaîne dépend de quelques acteurs américains ou chinois.

Dans la société

Désinformation : les deepfakes et textes générés deviennent indétectables

Emploi : l'automatisation touche désormais les métiers cognitifs qualifiés, pas seulement les tâches répétitives

Environnement : entraîner GPT-4 $\approx$ émissions de 500 vols Paris-New York. À l'échelle mondiale, l'empreinte carbone de l'IA explose.

Souveraineté : les données scientifiques européennes entraînent des modèles américains. Pour qui travaille-t-on vraiment ?

Votre génération est la première à entrer dans la vie professionnelle avec l'IA comme outil quotidien.

Vous n'aurez pas le luxe d'apprendre "plus tard".

Comprendre ces outils — leurs forces **et** leurs limites — est une compétence d'ingénieur au même titre que la thermodynamique ou la spectroscopie.

Améliorer le raisonnement : au-delà de la prédiction de token

Chain-of-Thought : penser étape par étape

Problème : les LLMs ont du mal avec le raisonnement multi-étapes

Solution : laisser le modèle "penser à voix haute"

Sans CoT : Q: $17 \times 23 = ?$ R: 371 ✗

Avec CoT : Q: $17 \times 23 = ?$ Réfléchissons étape par étape. R: $17 \times 20 = 340$. $17 \times 3 = 51$. $340 + 51 = 391$ ✓

OpenAI o1 / o3 (2024) : entraîné spécifiquement à raisonner
→ Performances proches des experts en maths olympiques et coding

Reasoning as Test-Time Compute

Idée centrale : au lieu de dépenser tout le compute à l'entraînement, allouer plus de compute à l'inférence (réfléchir plus longtemps)

Self-Consistency : générer N raisonnements, voter pour la réponse majoritaire

Tree of Thoughts : explorer un arbre de raisonnements possibles

Process Reward Model : évaluer la qualité de chaque étape intermédiaire, pas seulement la réponse finale

→ La "pensée lente" de Kahneman appliquée aux LLMs


Les Agents IA : de l'assistant à l'acteur autonome

Un agent IA n'est pas juste un chatbot :

- Il planifie
- Il agit via des outils
- Il boucle sur les retours de l'environnement

Architecture d'un agent

Un agent = LLM + outils + mémoire + boucle de décision



Outils typiques :

- Recherche web / bases scientifiques
- Exécution de code (calculs, DFT...)
- Accès à des instruments de labo
- Appels à d'autres agents spécialisés

Applications en chimie

ChemCrow (2023) : agent LLM avec 18 outils chimiques

→ Synthèse autonome de chloroquine

→ Planification de synthèses complexes

Autonomous Chemical Research (Nature, 2023) :

Agent couplé à bases chimiques, exécution de code et réactions robotisées

Agent IA + Self-Driving Lab : potentiel de chercheur semi-autonome (avec supervision humaine)

L'AGI : mythe ou horizon proche ?

Définitions en débat

AGI = Artificial General Intelligence → Un système capable d'accomplir toute tâche cognitive que peut accomplir un humain, dans n'importe quel domaine, sans entraînement spécifique.

Attention : ce n'est pas le même concept pour tous !

AGI est la capacité d'un système à apprendre n'importe quelle tâche aussi bien qu'un humain.

— OpenAI

AGI, c'est quand une IA peut générer suffisamment de valeur économique pour payer sa propre R&D.

— Sam Altman (pragmatique ?)

Ce qui manque encore (probablement)

- Compréhension causale : "corrélation $\neq$ causalité" — les LLMs confondent encore facilement
- Embodiment : comprendre le monde physique via l'expérience directe
- Efficacité des données : un enfant apprend en 1000× moins d'exemples
- Robustesse : distribution shift, adversarial examples
- Long-term planning : cohérence sur des tâches multi-jours

Prédictions d'experts : 2030 à "jamais" selon les experts...

→ La vraie question n'est peut-être pas "quand" mais "comment nous y préparer"

Défis et limites actuelles

Limites techniques

Hallucinations : génèrent des informations fausses avec confiance → risque critique en science

Contexte limité : même avec 1M tokens (Gemini), les modèles "oublent" en dehors du contexte

Coût énergétique : GPT-4 query ~0.001-0.01 kWh → ~10× une recherche Google. À l'échelle mondiale...

Biais : héritent des biais des données d'entraînement — corpus scientifique anglophone dominant

Défis éthiques et réglementaires

Droits d'auteur : les modèles entraînés sur des articles scientifiques — légal ?

Reproductibilité : les modèles propriétaires ne sont pas auditable

Impact emploi : automation de tâches cognitives qualifiées

IA Act (EU 2024) : premier cadre réglementaire mondial pour l'IA à haut risque

Pour la chimie : les CBRN (chimique, biologique, radiologique, nucléaire) sont un risque identifié des LLMs mal encadrés. Des garde-fous sont en place mais imparfaits.

Conclusion

Ce qu'il faut retenir

L'IA n'est pas magique

C'est de la statistique sur des données massives + de l'optimisation. Comprendre les principes permet d'utiliser l'IA intelligemment et d'identifier ses limites.

La chimie est un terrain privilégié

Données structurées, règles physiques, problèmes combinatoires → l'IA y excelle. AlphaFold, drug discovery, matériaux : la révolution est en cours.

L'humain reste indispensable

Interprétation des résultats, validation expérimentale, créativité scientifique, éthique — l'IA augmente mais ne remplace pas (encore) le chimiste.

Agissez maintenant

L'IA évolue à vitesse exponentielle. Ceux qui comprennent ces outils aujourd'hui seront mieux positionnés demain.

Ressources pour aller plus loin

Pour comprendre

- 3Blue1Brown — "Neural Networks" (YouTube) — visualisations exceptionnelles
- Andrej Karpathy — "Let's build GPT from scratch" (YouTube)
- Fast.ai — cours pratiques deep learning, gratuits en ligne
- The Illustrated Transformer — Jay Alammar (blog)

Pour la chimie

- DeepChem — bibliothèque ML pour la chimie (Python, open-source)
- AlphaFold DB — alphafold.ebi.ac.uk — 214M structures gratuites
- IBM RXN — rxn.app.accelerate.science — prédiction de réactions
- HuggingFace — modèles fine-tunés chimie (ChemBERTa, MolT5...)

Pour suivre l'actualité

- Papers With Code — suivi des SOTA en ML
- Nature Machine Intelligence — IA appliquée aux sciences
- The Batch (Andrew Ng) — newsletter hebdomadaire

Questions ?

Chimie ParisTech PSL
11 rue Pierre et Marie Curie
75005 Paris

 github.com/antoinesd/Prez-Intro-IA

Merci pour votre attention !

